

2.2 数值分析

上一节课，我们主要学习了如何对系统进行数学建模。值得注意的是：通常建模得到的微分方程（ODE 或 PDE）都没有显示解。那么，一个重要的问题是：我们如何对这样的微分系统进行定量分析？

2.2.1 常微分方程的数值模拟

当没有显示解的时候，我们可以利用数值模拟的方法对系统进行定量分析。

本课程主要考虑常微分系统。我们考虑受控后系统：

$$\dot{x}(t) = F(t, x(t)) \quad x(t_0) = x_0$$

该系统可以近似为离散时间系统：

$$\hat{x}(t_{i+1}) = \hat{x}(t_i) + F(t, \hat{x}(t_i))\Delta t \quad \hat{x}(t_0) = x_0 \quad t_{i+1} = t_0 + (i+1)\Delta t$$

从而，我们可以利用计算机通过对离散时间系统的迭代来近似求解原系统的解。该方法称为欧拉方法（Euler Method）；在一些条件下，该方法的精度为 $\mathcal{O}(\Delta t)$ 。除了欧拉方法，还有更高精度的数值方法，例如 Runge-Kutta 方法等。这些方法在数值分析课程中有详细的介绍，我们在本课程中不再赘述。

在 Python 中，我们可以调用 SciPy 库中的 `solve_ivp` 函数来进行数值模拟。该代码函数直接使用 Runge-Kutta 方法进行求解。在使用中，只需定义一个函数来表示系统的演化函数 $F(t, x)$ ，然后调用 `solve_ivp` 函数即可得到数值解。详见课程代码¹。

对于二维系统，我们可以通过绘制相图来直观地理解系统的动力学行为。在 Python 中，我们可以调用 matplotlib 库中的 `quiver` 函数来绘制向量场，并使用 matplotlib 库中的 `streamplot` 函数来绘制相图。详见课程代码。

2.2.2 参数估计/学习

在建模中，我们通常会遇到一些系统参数，例如弹簧模型中的弹性系数 k 、阻尼系数 c ，供暖系统中的热扩散系数 α 、换热系数 γ 等。这些参数如果已知，则可以直接代入模型进行分析；但在实际中，我们往往无法直接测量这些参数，需要通过实验数据来进行估计。这里我们继续考虑常微分方程模型：

$$\dot{x}(t) = F(t, x(t); \theta) \quad x(t_0) = x_0$$

¹文件 名: Lecture_2.2.ipynb; 下 载 地 址: https://github.com/ZhouFang92/Principles-of-Automatic-Control/blob/main/Lecture_2.2.ipynb

其中 θ 为系统参数向量。我们希望通过实验数据来估计 θ 的值。

全状态频繁测量下的参数估计方法

我们首先考虑一种理想化的情况：假设我们可以频繁地测量系统的状态 $x(t)$ 与输入 $u(t)$ ，即得到一组离散时间的测量数据 $\{(x(t_i), u(t_i))\}_{i=0}^N$ ，其中 $t_i = t_0 + i\Delta t$ ，且 Δt 较小。此时，我们根据微分方程，真实的参数 θ^* 应该近似满足

$$\frac{x(t_{i+1}) - x(t_i)}{\Delta t} \approx F(t_i, x(t_i); \theta^*)$$

从而，我们可以构造一个最小二乘问题来估计参数 θ ：

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=0}^{N-1} \left\| \frac{x(t_{i+1}) - x(t_i)}{\Delta t} - F(t_i, x(t_i); \theta) \right\|^2$$

这个是一个标准的优化问题，我们可以通过最速下降法等数值方法进行计算。在 Python 中，我们可以使用 PyTorch 库中的自动求导功能来计算梯度，从而实现参数的优化估计。

非理想数据情况下的参数估计方法

在实际系统中，我们往往无法频繁地测量系统的状态，甚至只能测量系统的部分状态。此时，我们无法直接使用上述方法来估计参数 θ ，需要使用一些更复杂的方法。这里，我们考虑观测的时间依然为 $\{t_i\}_{i=0}^N$ ，但它们的间隔不一定很小；同时观测的可能是系统的输出 $y(t)$ ，满足

$$y(t_i) = h(x(t_i)) \quad i = 0, 1, \dots,$$

我们记 $\Psi(t, x_0; \theta)$ 为目标系统在初值 x_0 与参数 θ 下的解。真实参数 θ^* 满足

$$y(t_i) = h(\Psi(t_i, x_0; \theta^*))$$

因此，我们可以构造一个优化问题来估计参数 θ ：

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=0}^N \|y(t_i) - h(\Psi(t_i, x_0; \theta))\|^2$$

对于这样的系统，我们可以通过数值模拟的方法来计算 $\Psi(t_i, x_0; \theta)$ ，然后使用梯度下降等优化算法来求解 $\hat{\theta}$ 。在 Python 中，为了与 PyTorch 的自动求导机制相兼容，

可以使用 `torchdiffeq` 库对 ODE 进行数值求解。该库支持基于 PyTorch 计算图的梯度计算，因此可以结合自动求导机制获得模型参数相对于目标函数的梯度，并通过梯度优化方法实现参数的估计与更新。

注记：这种将 ODE 数值求解与基于梯度的参数优化相结合的方法，也正是 Neural ODE 等经典神经网络方法的核心。

系统估计与辨识是控制系统中非常重要的一个环节，有许多理论与方法。我们在本课程中仅介绍最基本的参数估计方法，更多内容请参考控制系统相关教材或修读系统辨识课程。

2.2.3 系统框图 (Block Diagram)

框图是系统建模中常用的一种图形化表示方法。它通过使用不同的图形符号来表示系统的各个组成部分及其之间的关系，从而直观地展示系统的结构和功能。在复杂系统建模中，我们也可以将整体系统分割为若干个子系统，并使用框图来表示各个子系统之间的关系，从而达到简化系统建模、分析的目的。

在框图中，通常用**方框**表示系统的一个组成部分（子系统），用**带箭头的线段**表示信号的流向，用**圆圈（求和点）**表示信号的相加或相减。




图 2.3: 一个化工过程的框图示意图，每个框表示一个子系统，可以单独建模分析。